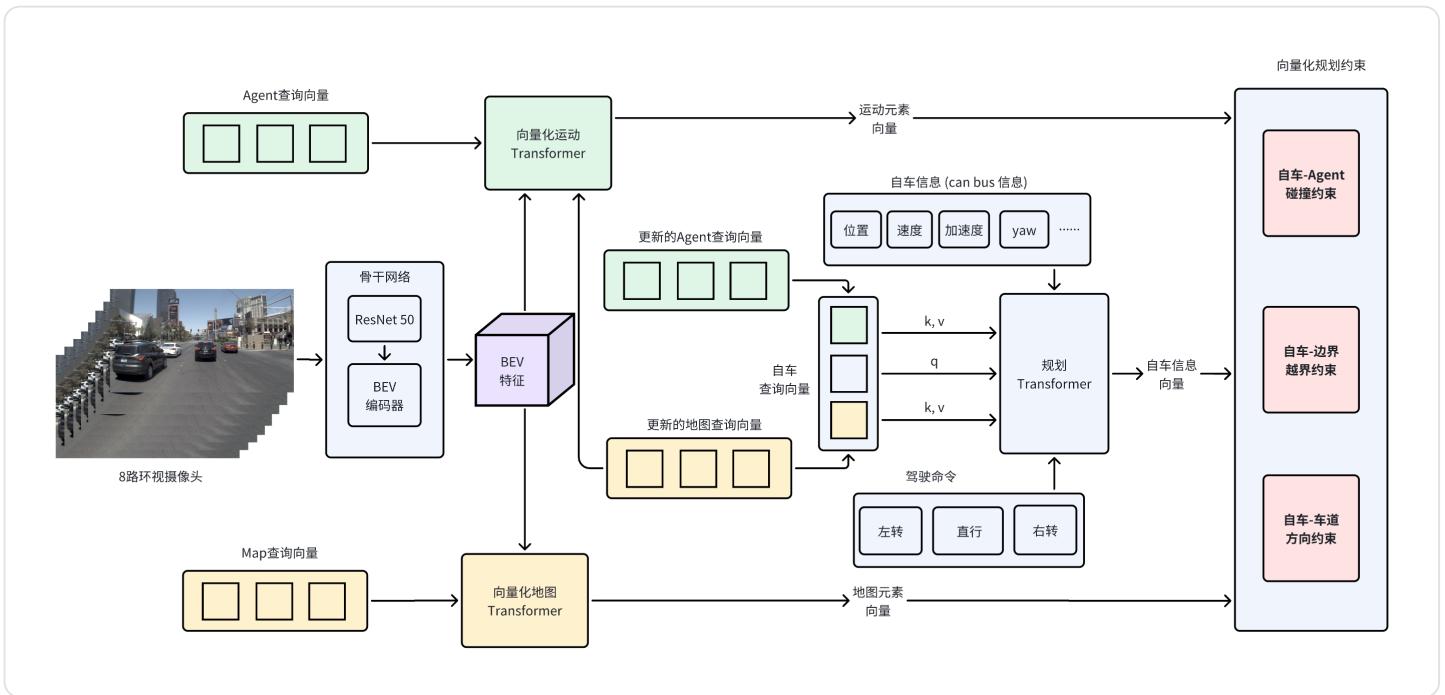


光轮端到端模型交付报告

1. 模型信息

1.1 模型架构



1. 骨干网络特征提取阶段：

- 输入：多帧、多视角的图像输入。 (8个cameras)
- 处理：
 - ResNet50将多视角图像来编码图像特征。
 - BEV编码器将图像特征转换为鸟瞰图(BEV)特征。
- 输出：BEV特征

2. 向量化场景学习阶段 (Vectorized Scene Learning) :

- 向量化地图 (Vectorized Map) :** 使用一组Map queries从BEV特征图中提取地图信息，并预测地图向量和每个地图向量对应的类别分数。考虑了**三种地图元素**：车道分隔线(divider)、道路边界(boundary)和人行横道(ped_crossing)。
 - 输入：地图查询 (Map Queries) 和BEV特征
 - 处理：向量化地图Transformer (Vectorized Map Transformer)
 - 输出：
 - 更新后的地图查询 (Updated Map Queries)

- 运动向量 (Motion Vector) : 表示其他车辆的预测轨迹
- 向量化Agent运动 (Vectorized Agent Motion) : 使用一组Agent queries通过Deformable Attention从共享的BEV特征图中学习agent级别的特征。agent的属性 (位置、类别、方向等) 通过基于MLP的解码头从agent queries中解码得到。
 - 输入: Agent查询 (Agent Queries) 和BEV特征
 - 处理: 向量化运动Transformer (Vectorized Motion Transformer)
 - 输出:
 - 更新后的Agent查询 (Updated Agent Queries)
 - 地图向量 (Map Vector) : 表示道路结构等静态环境信息

3. 规划推理阶段 (Planning) :

- Planning via Interaction: 使用一个随机初始化的Ego Query通过与agent queries和map queries的交互来隐式学习场景特征。
- Planning Head: 采用一个简单的基于MLP的planning head, 结合ego queries、ego state特征和高级驾驶命令(high-level command)来输出规划轨迹。

4. 向量化规划约束 (Vectorized Planning Constraints) : 引入三个向量化规划约束, 用于优化规划结果。

- Ego-Agent碰撞约束 (Ego-Agent Collision Constraint)
 - 输入: Ego向量和运动向量
 - 目的: 确保规划的轨迹与其他车辆保持安全距离
- Ego-边界越界约束 (Ego-Boundary Overstepping Constraint)
 - 输入: Ego向量和地图向量
 - 目的: 确保规划的轨迹不会越过道路边界
- Ego-车道方向约束 (Ego-Lane Directional Constraint)
 - 输入: Ego向量和地图向量
 - 目的: 确保规划的轨迹方向与车道方向一致

1.2 模型参数量

- 58406845

1.3 训练情况

超参数	参数	值
-----	----	---

	initial_lr	5e-4
	lr_policy	CosineAnnealing
	weight_decay	0.01
	warmup	linear
	warmup_iters	500
	warmup_ratio	1.0 / 3
	min_lr_ratio	1e-3
	batch_size	3*8GPU
训练平台	GPU	8卡H800(80GB)
	OS	Ubuntu 22.04.3 LTS
	CPU	Intel(R) Xeon(R) Gold 6448Y
	Memory	2TB
迭代次数	Epoch	20
	Step	20000 steps/epoch
数据量	train	480,000 frames

2. 开环评测指标

模块	指标	全称	含义
Motion	ADE	Average Displacement Error	在预测轨迹和真实轨迹之间，平均点对点 L2距离。
	FDE	Final Displacement Error	预测的最终点和真实轨迹的最终点之间的 L2距离
	MR	Miss Rate	如果预测和真实轨迹之间最大的点对点L2 距离超过2米，则定义这个预测为miss

Planning	plan_L2_1s		未来1s时，预测轨迹与真实轨迹的L2距离
	plan_L2_2s		未来2s时，预测轨迹与真实轨迹的L2距离
	plan_L2_3s		未来3s时，预测轨迹与真实轨迹的L2距离
	plan_obj_col_1s		未来1s时发生碰撞的概率
	plan_obj_col_2s		未来2s时发生碰撞的概率
	plan_obj_col_3s		未来3s时发生碰撞的概率
Detection	AP	Average Precision	目标检测的平均精度
	ATE	Average Translation Error	预测轨迹与真实轨迹的平均位置误差
	ASE	Average Scaling Error	预测轨迹与真实轨迹的平均缩放误差
	AOE	Average Orient Error	预测轨迹与真实轨迹的平均旋转误差
	AVE	Average Velocity Error	预测轨迹与真实轨迹的平均速度误差
Map Prediction	mAP@0.5	Mean Average Precision	阈值为0.5m时，地图预测的平均精度均值
	mAP@1	Mean Average Precision	阈值为1m时，地图预测的平均精度均值
	mAP@1.5	Mean Average Precision	阈值为1.5m时，地图预测的平均精度均值
	mAP	Mean Average Precision	上述3种阈值下的mAP的均值

3. 模型评测结果

3.1 Motion

指标	分数
ADE_car	0.42
ADE_pedestrian	0.50
FDE_car	0.48
FDE_pedestrian	0.49
MR_car	0.02
MR_pedestrian	0.01
EPA_car	0.81
EPA_pedestrian	0.40

3.2 Planning

指标	分数
plan_L2_1s	0.26
plan_L2_2s	0.45
plan_L2_3s	0.69
plan_obj_col_1s	0.0
plan_obj_col_2s	0.0
plan_obj_col_3s	0.0

3.3 Detection

类别	AP	ATE	ASE	AOE	AVE
vehicle	0.710	0.255	0.091	1.581	6.554
generic_object	0.546	0.515	0.077	1.020	1.414
traffic_cone	0.074	1.416	0.214	NaN	NaN
pedestrian	0.161	0.682	0.146	1.690	1.777
bicycle	0.015	0.284	0.451	1.348	1.348

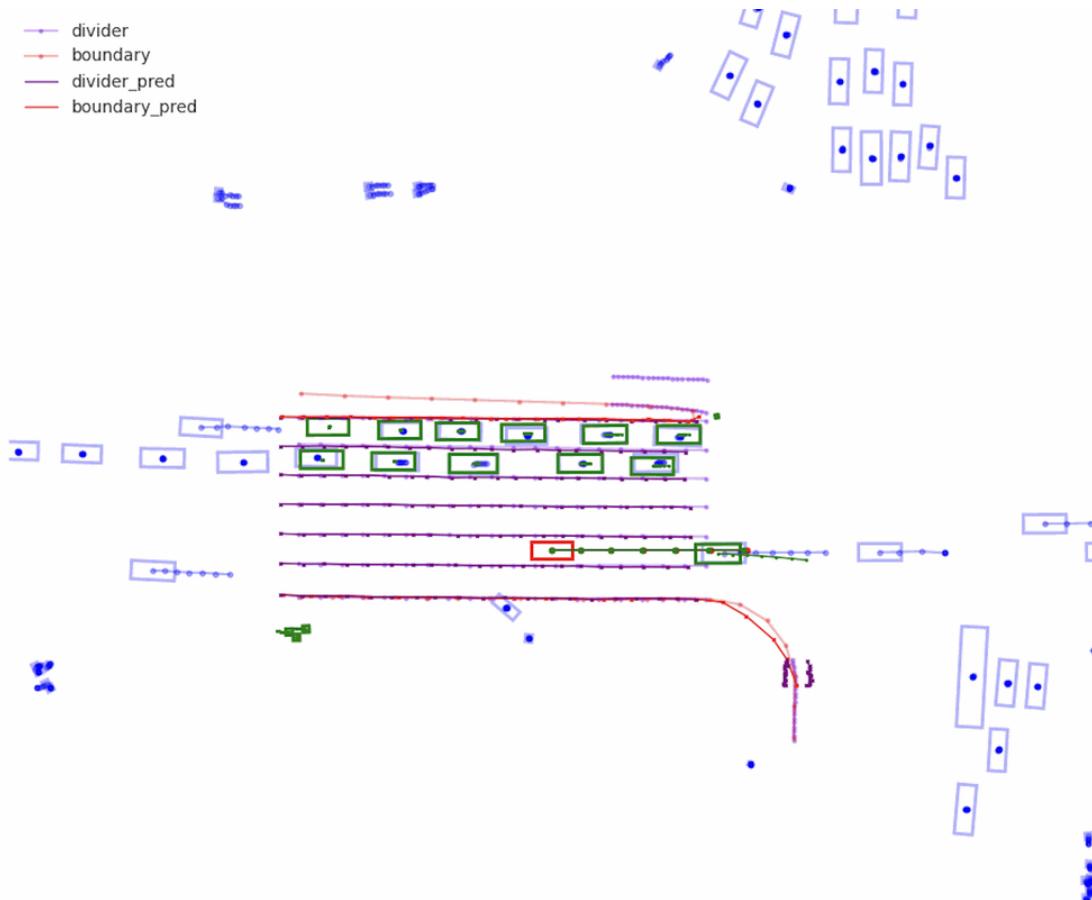
3.4 Map

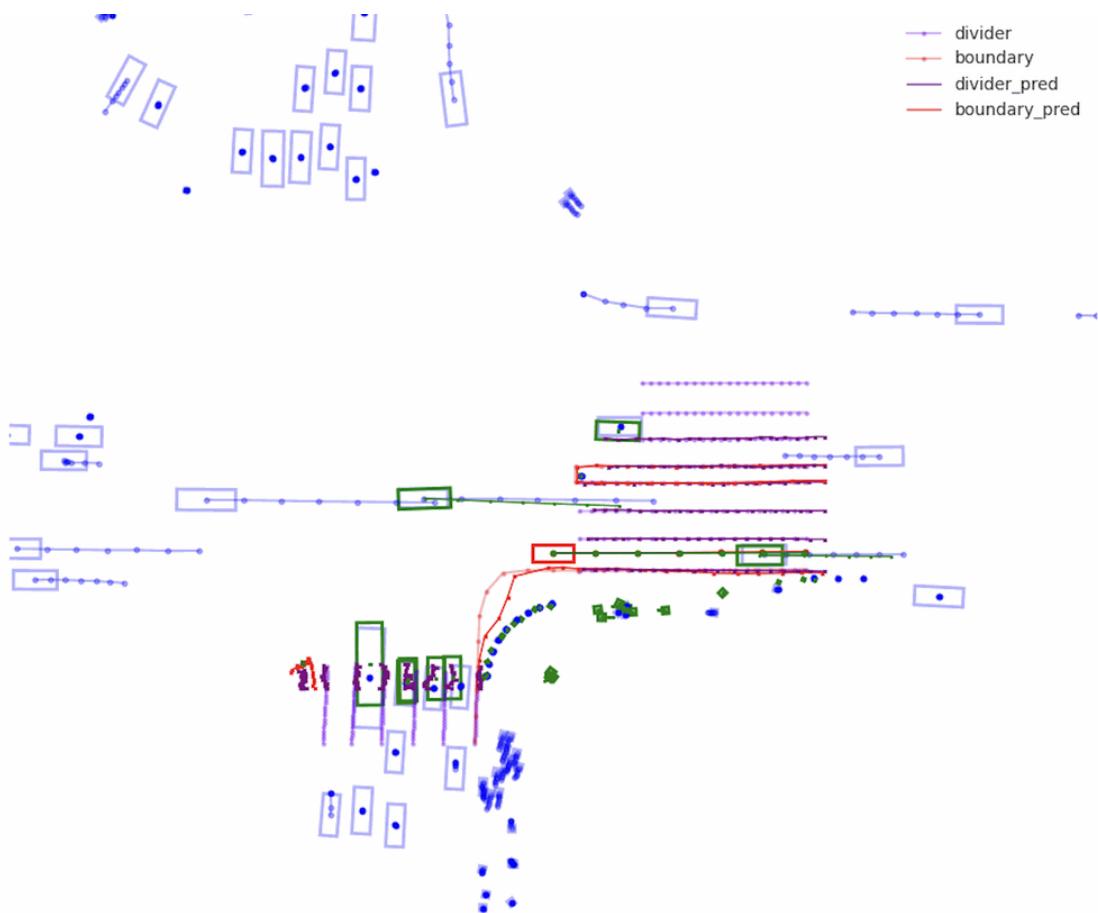
类别	AP@0.5	AP@1	AP@1.5
divider	0.826	0.922	0.958
ped_crossing	0.521	0.794	0.912
boundary	0.784	0.922	0.947

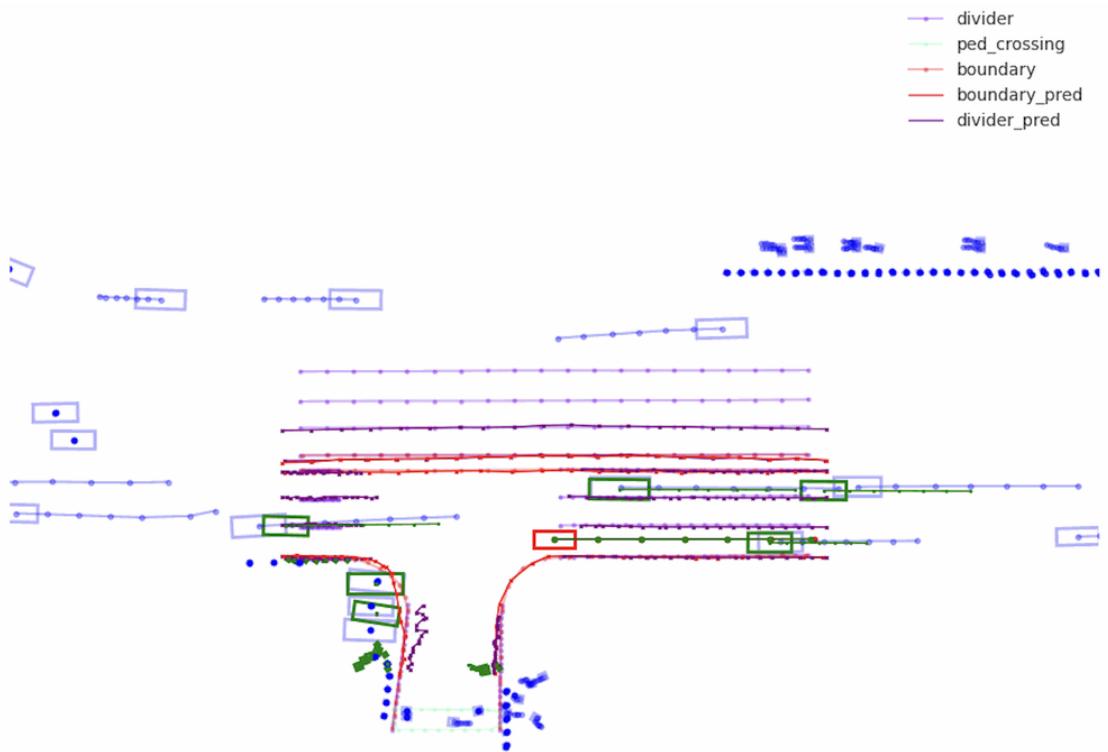
3.5 可视化结果

淡紫色框为bbox的gt，绿色框为预测，红色框为自车，自车轨迹的gt为红色，自车轨迹的预测为绿色。

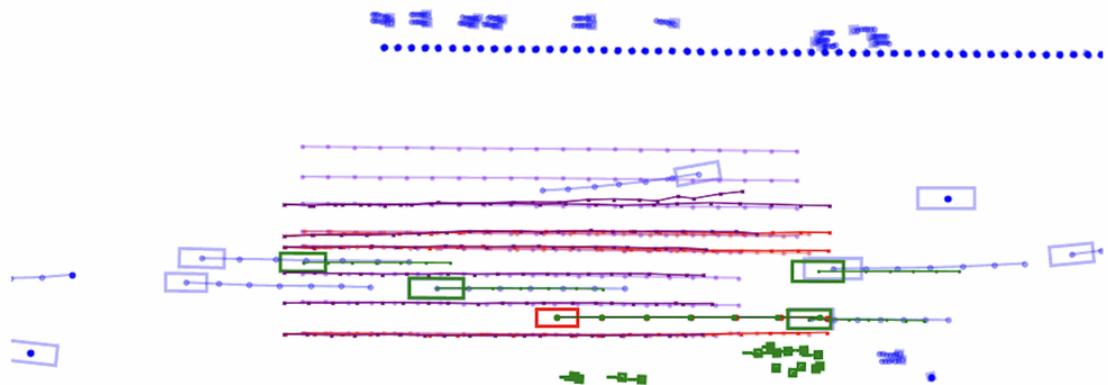
地图的gt与预测如图例所示。

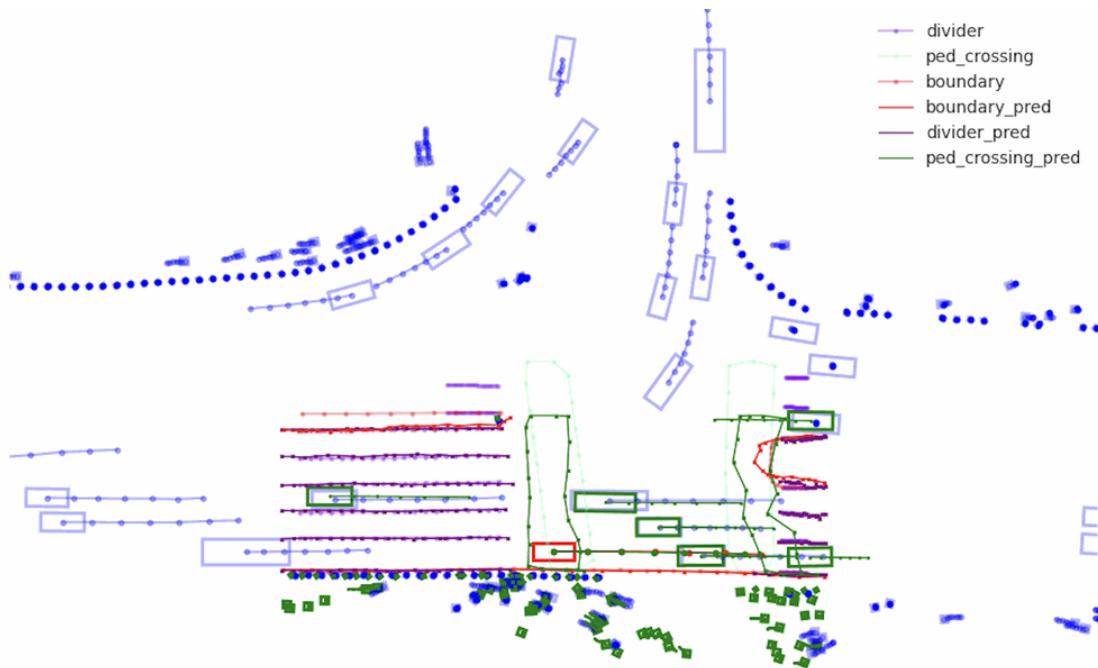




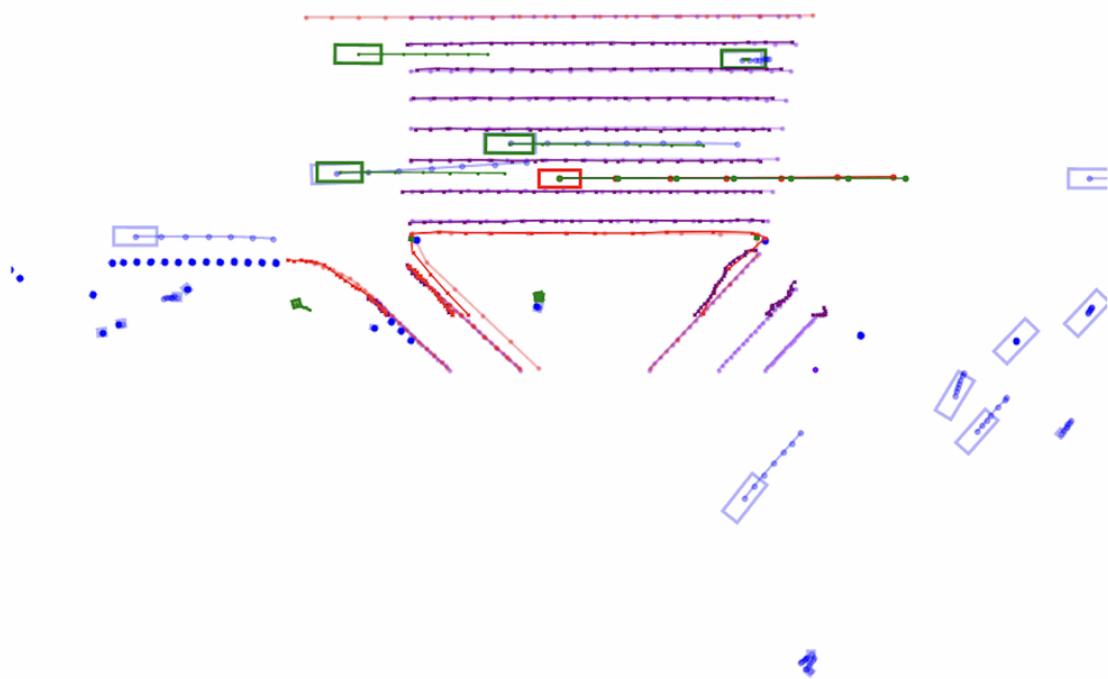


divider
boundary
boundary_pred
divider_pred





divider
boundary
divider_pred
boundary_pred



divider
ped_crossing
boundary
boundary_pred
divider_pred
ped_crossing_pred

